

LUIS ROMERO
AI Engineer | Backend Developer (Node.js/TypeScript)
Barranquilla, Colombia | +57 324 492 6589 | lueduar15@gmail.com
linkedin.com/in/luisromero15 | github.com/ROMEROLUIS15 | cronix-app.vercel.app

RESUMEN PROFESIONAL

Backend Developer / AI Engineer con 2+ años de experiencia construyendo y operando productos de IA en producción. Fundé y opero Cronix, un SaaS multi-tenant 24/7 con 150+ citas reales gestionadas de forma autónoma por un motor de orquestación de IA propio —sin framework— para WhatsApp y voz (tool calling restringido), respaldado por una arquitectura anti-alucinación determinista y un sistema propio de evaluación (DeepEval) y observabilidad (LangSmith) de extremo a extremo. También construí el backend de IA de una plataforma institucional con asistente conversacional, RAG y búsqueda semántica sobre pgvector (LangGraph, IBIME), y el de un CMMS industrial; además integré pagos, OAuth, chat en tiempo real y video en una plataforma de teleterapia. Stack principal: Node.js, TypeScript, PostgreSQL/SQL, arquitectura serverless y event-driven.

EXPERIENCIA

Backend / Full-Stack Developer | IBIME (Plataforma institucional, Remoto)

Enero 2025 - Presente

- Diseñé, construí y desplegué de punta a punta la plataforma digital de una red pública de bibliotecas (reemplazando un sistema legacy en HTML/CSS), con un asistente de IA para consultas ciudadanas; adoptada por la institución, con requerimientos levantados con bibliotecarios y el área de informática.
- Diseñé un motor de chat híbrido con arquitectura anti-alucinación de 5 capas (Intent Classifier, Privacy Gate, umbral RAG fail-hard, Response Guardrail y Response Policy) que mantiene el LLM fuera del flujo crítico: cuando el correo es conocido responde directamente desde la base de datos, eliminando llamadas al LLM y alucinaciones en esas consultas.
- Implementé RAG y búsqueda semántica sobre PostgreSQL + pgvector (embeddings Gemini) con caché en Redis y un rate limiter propio con degradación elegante, y un agente LangGraph con estado (extractor-validador-corrector) que estructura PDFs de catálogo en JSON validado con verificación de duplicados fail-closed.
- Apliqué arquitectura hexagonal e inyección de dependencias con principios SOLID y Zod compartido front-back; CI con 230+ tests (Vitest + Playwright); desplegado en Render + Vercel.

Backend Developer | Kiura (Barranquilla, Colombia, Remoto)

Abril 2024 - Diciembre 2024

- Construí servicios backend de una plataforma de teleterapia (pacientes-terapeutas) que unifica pagos por suscripción, citas, mensajería en tiempo real y videoseSIONES; desplegado en Render con base de datos relacional aprovisionada en AWS (RDS).
- Integré pagos por suscripción con MercadoPago (alta, cancelación, webhook) que activan o suspenden el acceso, chat en tiempo real con Socket.IO y videoseSIONES con tokens RTC firmados de Agora por sala.
- Implementé doble autenticación (JWT + Google OAuth) con RBAC sobre un dominio relacional de 26 entidades en MySQL/Sequelize con agenda y detección de conflictos.

PROYECTOS

Fundador y AI / Backend Engineer | Cronix

Enero 2026 – Presente

SaaS multi-tenant para negocios con citas, construido y desplegado de punta a punta de forma autónoma (BD, backend serverless, IA e infraestructura); en producción 24/7 con 150+ citas reales gestionadas y recordatorios automáticos por pg_cron, sin intervención manual.

- Construí el agente conversacional que agenda, reagenda y cancela citas por WhatsApp y voz de forma autónoma y 24/7 el cliente lo resuelve hablando, sin intervención humana (motor de orquestación propio, tool calling restringido, Groq + Deepgram, 12 capacidades).
- Diseñé los controles que evitan que el agente invente datos (alucinaciones) o actúe sobre el cliente o la cita equivocada el riesgo principal de conectar un LLM a una BD real: arquitectura determinista de 6 capas / ~13 mecanismos (fast paths, confirmation-gate de 2 turnos y function calling restringido a args declarados, entre otros).
- Construí el sistema que mide y monitorea la fiabilidad del agente: regression suite con LLM-as-judge (DeepEval) sobre golden datasets versionados, integrada en CI, y tracing multi-tenant (PostgreSQL + export a LangSmith) con dashboard de latencia p50/p95 por negocio, sobre 9 Edge Functions serverless (Deno).
- Aislé los datos de cada negocio con PostgreSQL RLS (59 políticas / 32 tablas, validado con 138 asserts pgTAP) y auth híbrida JWT + WebAuthn/Passkeys con rate limiting sobre Redis; integré 4 métodos de pago (PayPal, NOWPayments, Pago Móvil, Binance) con fulfillment idempotente y procesamiento async vía QStash.
- Sostuve la calidad con 1,000+ tests (Vitest, Playwright E2E, pgTAP), CI/CD (GitHub Actions + Vercel) con Sentry y Spec-Driven Development con verificación de drift en CI; integré servidores MCP (PayPal, Supabase, LangSmith) como tooling de agentes.

CMMS Hidrobombas Mérida (Remoto) | Desarrollador Full-Stack

Abril 2026 - Presente

- Diseñé y desplegué de punta a punta un CMMS (52 endpoints REST sobre 11 modelos de datos) que reemplazó la hoja de inspección en papel de una empresa de mantenimiento industrial; requerimientos levantados con el cliente en entregas iterativas.
- Construí un asistente de IA con orquestación multi-agente (LangGraph): agente con tool calling + grafo de diagnóstico multinodo, con RAG sobre el historial de reportes; capa de IA testeable vía inyección de dependencias y vector store intercambiable (in-memory / pgvector).
- Implementé auth JWT con refresh rotativo y revocación server-side, autorización por rol + ownership, idempotencia, rate limiting y streaming por SSE; entregué además una PWA React 19 con modo offline (IndexedDB + Background Sync) y reportes PDF; 394 tests (82% cobertura de líneas en backend) y CI con BD dual (PostgreSQL/Neon + SQLite).

Clon de Twitter/X (reto técnico) | Full-Stack Developer 2026

- Implementé auth propia endurecida (JWT HS256 con algoritmo fijado, validación del usuario contra DB en cada request, bcrypt y guard de arranque contra secretos débiles en producción) y tiempo real por Server-Sent Events con pub/sub por tópicos, sin polling.
- Modelé el social graph con unicidad compuesta a nivel DB (follow/like idempotentes) sobre Prisma con SQLite (dev) y PostgreSQL (Docker); stack Docker Compose multiservicio y pirámide de pruebas en 3 niveles (138 integración Supertest, 54 componente, 10 E2E Playwright).

HABILIDADES TÉCNICAS

Backend: Node.js, TypeScript, Express.js, REST API, RESTful APIs, Serverless, Edge Functions, Deno, Event-Driven Architecture, Webhooks, Webhook Processing, Idempotency, SOLID Principles, OOP, Dependency Injection, Hexagonal Architecture, Socket.IO, WebSockets, Agora RTC

IA: LLM Integration, LangChain, LangGraph, Agentic Systems, Multi-Agent Orchestration, Tool Calling, Function Calling, Retrieval-Augmented Generation (RAG), Semantic Search, Vector Databases (pgvector), Anti-Hallucination, LLM Evaluation (DeepEval), LLM Observability (LangSmith), Model Context Protocol (MCP), Voice AI, Groq, Gemini, Hugging Face, Deepgram, OpenAI-compatible API, n8n, Workflow Automation

Bases de datos: PostgreSQL, SQL, AWS (RDS), MySQL, Sequelize, Supabase, SQLite, Redis, Upstash Redis, pgvector, Row-Level Security, Multi-tenant

Seguridad/Auth: JWT, OAuth 2.0, WebAuthn, Passkeys, RBAC, Rate Limiting

Pagos/Async: PayPal REST API, MercadoPago, Payment Integration, Upstash QStash, Async Processing, Message Queues, Server-Sent Events (SSE), Circuit Breaker

DevOps/Testing: Docker, GitHub Actions, CI/CD, Spec-Driven Development, Vercel, Render, Sentry, Observability, Vitest, Jest, Unit Testing, Integration Testing, E2E Testing, Playwright, pgTAP, fast-check

Frontend: React, Next.js 15, App Router, Server Actions, SSR, Tailwind CSS, TanStack Query, Zod, PWA, Service Workers, i18n

EDUCACIÓN

- TSU en Mantenimiento de Sistemas Informáticos
Universidad Nacional Abierta - Graduación esperada: Dic 2026
- Bootcamp Full-Stack | Academlo - Mar 2024 (Node.js, React, PostgreSQL, Express, HTML, CSS)

IDIOMAS

Español: Nativo

Inglés: Intermedio (B1+) | Lectura y documentación técnica avanzada; comunicación profesional en mejora